

MaxSPRT: vigilancia secuencial de seguridad de
vacunas

Un test de razón de verosimilitud secuencial con alternativa compuesta

Santiago Dandois y Santiago Olszevicki

Basado en Kulldorff, Davis, Kolczak, Lewis, Lieu y Platt (2011), *A Maximized Sequential Probability Ratio Test for Drug and Vaccine Safety Surveillance*, Sequential Analysis 30(1).

Los ensayos clínicos no alcanzan para detectar eventos adversos raros: muestra chica y población más homogénea que la real. Una vez en el mercado, hay que seguir vigilando.

Importa **revisar la evidencia en forma continua/casi continua**, controlando los falsos positivos.

¿Qué es el riesgo relativo?

$$RR = \frac{\text{casos observados}}{\text{casos esperados sin efecto de la vacuna}}$$

- $RR = 1$: no hay exceso, todo como se esperaba.
- $RR = 2$: el doble de casos que los esperados.
- $RR = 1.2$: un 20% más de casos que lo esperado.

SPRT clásico (Wald, 1945-47)

C_t : eventos adversos observados hasta t (en D días); μ_t los esperados bajo H_0 . El SPRT contrasta dos hipótesis **simples**:

$$H_0 : C_t \sim \text{Poisson}(\mu_t) \quad (\text{RR} = 1) \quad \text{vs.} \quad H_A : C_t \sim \text{Poisson}(\text{RR } \mu_t) \quad (\text{RR fija, a priori})$$

El estadístico es la razón de verosimilitudes $\text{LR}_t = P(\text{datos}|H_A)/P(\text{datos}|H_0)$. Para armarla, partimos $[0, t]$ en intervalos $i = 1, \dots, t$ con n_i eventos y μ_i esperados, independientes:

$$n_i \sim \text{Poisson}(\mu_i) \quad \text{bajo } H_0, \quad n_i \sim \text{Poisson}(\text{RR } \mu_i) \quad \text{bajo } H_A$$

La verosimilitud conjunta es la productoria de las densidades Poisson:

$$L_t(\text{RR}) = \prod_{i=1}^t \frac{e^{-\text{RR } \mu_i} (\text{RR } \mu_i)^{n_i}}{n_i!}$$

SPRT clásico: de la verosimilitud al estadístico

Reagrupando la productoria (exponenciales se suman, potencias de $\mathbf{RR}$ se acumulan):

$$L_t(\mathbf{RR}) = e^{-\mathbf{RR} \mu_t \mathbf{RR}^{c_t}} \prod_{i=1}^t \frac{\mu_i^{n_i}}{n_i!}$$


con $\mu_t = \sum_i \mu_i$ y $c_t = \sum_i n_i$. El último factor no depende de $\mathbf{RR}$ y se cancela en el cociente:

$$\text{LR}_t = \frac{L_t(\mathbf{RR})}{L_t(1)} = e^{(1-\mathbf{RR})\mu_t \mathbf{RR}^{c_t}} \Rightarrow \text{LLR}_t = (1 - \mathbf{RR})\mu_t + c_t \ln(\mathbf{RR})$$

Regla: señal si $\text{LLR}_t \geq \ln[(1 - \beta)/\alpha] = 2.77$; se acepta H_0 si $\text{LLR}_t \leq \ln[\beta/(1 - \alpha)] = -1.56$ ($\alpha = 0.05, \beta = 0.20$).

Hay que fijar el $\mathbf{RR}$ de antemano — ese “detalle” es el problema.

El problema del SPRT clásico (I): fiebre




Pediarix, ≈ 650.000 chicos (Vaccine Safety Datalink). El RR verdadero termina en ≈ 1.16 .

- con $H_A : RR = 1.2$ (cerca del real) $\rightarrow$ **señal a las 13 sem.**
- con $H_A : RR = 2.0$ (lejos del real) $\rightarrow$ cruza el límite inferior y **acepta H_0 a las 7 sem:** no detecta nada.

La alternativa mal elegida (2.0) hace **perder** un riesgo real.

El problema del SPRT clásico (II): síntomas neurológicos



Mismos datos, otro evento. Acá el RR verdadero termina en ≈ 2.75 .

- con $H_A : RR = 2.0$ (cerca del real) $\rightarrow$ **señal a las 32 sem.**
- con $H_A : RR = 1.2$ (lejos del real) $\rightarrow$ **señal recién a las 65 sem.**

Ambas detectan, pero elegir mal el RR **retrasa la señal** casi 8 meses: el tiempo hasta la alarma depende del RR fijado a priori, que casi nunca conocemos.

La idea de MaxSPRT

El SPRT clásico obliga a fijar el **RR** de la alternativa antes de ver los datos.

MaxSPRT usa una alternativa **compuesta**:

$$H_0 : \text{RR} = 1 \quad \text{vs.} \quad H_A : \text{RR} > 1$$

Clave: se **apoya en el mismo LLR_t ya deducido**. En vez de un **RR** fijo, se usa el **RR** que maximiza la verosimilitud — estimado de los datos, no elegido a priori:

$$\text{LLR}_t = \max_{\text{RR} > 1} [(1 - \text{RR})\mu_t + c_t \ln(\text{RR})]$$

(razón de verosimilitud generalizada, Lorden 1973). No hay que adivinar el **RR** “interesante”: el test busca el que mejor explica lo observado. Se paga algo de potencia, pero es mucho más robusto.

Derivando LLR_t respecto de RR e igualando a cero, el máximo se da en el RR que iguala lo observado con lo esperado:

$$\frac{\partial LLR_t}{\partial RR} = -\mu_t + \frac{c_t}{RR} = 0 \Rightarrow \widehat{RR}_t = \frac{c_t}{\mu_t}$$

Es el estimador de máxima verosimilitud: **reemplaza al RR fijo de la alternativa.** Sustituyéndolo en LLR_t se obtiene el estadístico final.

Sustituyendo $\widehat{RR}_t = c_t / \mu_t$:

$$LLR_t = (\mu_t - c_t) + c_t \ln \left(\frac{c_t}{\mu_t} \right)$$

y $LLR_t = 0$ si $c_t < \mu_t$ (no hay evidencia de exceso).

Regla, monitoreada continuamente:

- se sigue vigilando mientras LLR_t no llegue a un valor crítico V
- se rechaza H_0 apenas $LLR_t \geq V$ (señal)
- ya no hay límite inferior para “aceptar” H_A - no interesa frenar si la vacuna resulta protectora
- sí hay un límite superior T en la duración de la vigilancia (cantidad esperada de eventos bajo H_0), para no vigilar para siempre

Y si no tenemos μ_t confiable...

A veces no hay tasa basal esperada confiable. Se compara directamente tiempo expuesto vs. no expuesto (diseño pareado, en vez de Poisson):

- autocontrolado: mismo individuo, ventana expuesta vs. no expuesta
- con controles: expuestos vs. no expuestos, pareados por edad/sexo

Cada evento es como tirar una moneda: cae del lado expuesto o no. Sea z la duración del período no expuesto sobre la del expuesto ($z = 1$ para un pareo 1:1).

$$H_0 : P(\text{expuesto}) = \frac{1}{z + 1} \quad H_A : P(\text{expuesto}) = \frac{\text{RR}}{\text{RR} + z}$$

El límite de vigilancia ya no se mide en eventos esperados (T) sino en eventos observados en total (N).

MaxSPRT binomial: la verosimilitud

Sea c_n la cantidad de esos n eventos que cae del lado expuesto. Condicional en n , C_n es binomial (prob. p de caer expuesto):

$$P(C_n = c_n) = \binom{n}{c_n} p^{c_n} (1 - p)^{n - c_n}$$

Esa p depende del RR: $p(\text{RR}) = \text{RR}/(\text{RR} + z)$ y $1 - p = z/(\text{RR} + z)$. Reemplazando:

$$P(C_n = c_n \mid \text{RR}) = \binom{n}{c_n} \left(\frac{\text{RR}}{\text{RR} + z} \right)^{c_n} \left(\frac{z}{\text{RR} + z} \right)^{n - c_n}$$

El cociente contra H_0 ($p = 1/(z + 1)$) cancela $\binom{n}{c_n}$ y se maximiza sobre $\text{RR} > 1$:

$$\text{LR}_{n(\text{RR})} = \frac{\left(\frac{\text{RR}}{\text{RR} + z} \right)^{c_n} \left(\frac{z}{\text{RR} + z} \right)^{n - c_n}}{\left(\frac{1}{z + 1} \right)^{c_n} \left(\frac{z}{z + 1} \right)^{n - c_n}}$$

MaxSPRT binomial: maximización y estadístico

Maximizar la binomial sobre p da el estimador de proporción $\hat{p} = c_n/n$, que corresponde a $\widehat{\text{RR}}_n = zc_n/(n - c_n)$. Reemplazando, el numerador queda

$$(c_n/n)^{c_n} ((n - c_n)/n)^{n-c_n}$$

y el estadístico es:

$$\text{LLR}_n = c_n \ln\left(\frac{c_n}{n}\right) + (n - c_n) \ln\left(\frac{n - c_n}{n}\right) - c_n \ln\left(\frac{1}{z + 1}\right) - (n - c_n) \ln\left(\frac{z}{z + 1}\right)$$

(válido si $zc_n/(n - c_n) > 1$; si no, $\text{LLR}_n = 0$: no hay exceso del lado expuesto).


Misma lógica que el caso Poisson —alternativa compuesta $\text{RR} > 1$, maximización de la verosimilitud, tablas de valores críticos— pero partiendo de la binomial en vez de la Poisson.

V controla el error de tipo I: el valor más chico tal que, bajo H_0 , la probabilidad de cruzarlo alguna vez antes de T sea α .

$$P_{H_0}(\exists t \leq T : \text{LLR}_t \geq V) = \alpha$$

No hay fórmula cerrada: α se calcula con una recursión numérica bajo H_0 , y se ajusta V hasta ese valor. Tabulado por (α, T) una vez, no hace falta recalcularlo.

Valores críticos y ejemplo numérico



Un ejemplo concreto

Para $\alpha = 0.05$, algunos valores críticos de la Tabla 1 del paper:

- $T = 2 \rightarrow V \approx 3.05$
- $T = 10 \rightarrow V \approx 3.47$
- $T = 800$ (vigilancia larga, ≈ 2 años) $\rightarrow V \approx 4.29$

A mayor T , mayor V : se permiten más chances de cruzarlo por azar, así que hace falta una señal más fuerte para mantener el mismo α .

Con $T = 2$ y $\mu_t = 1$: si $c_t = 4$, $\text{LLR}_t = (1 - 4) + 4 \ln(4) \approx 2.55$, todavía no alcanza $V = 3.05$. Con $c_t = 5$: $\text{LLR}_t = (1 - 5) + 5 \ln(5) \approx 4.05$, cruza el límite y se rechaza H_0 .

La potencia depende del RR verdadero y de T .

- T chico: se termina antes, pero cuesta detectar riesgos moderados.
- T grande $\rightarrow$ más chances de cruzar por azar $\rightarrow V$ tiene que ser más alto $\rightarrow$ toma más tiempo acumular esa evidencia (sobre todo para riesgos moderados).

El mismo trade-off de siempre entre muestra y potencia, definido en eventos esperados bajo H_0 en vez de un n fijo. Como es vigilancia observacional, estirar T casi solo cuesta cómputo.

Por dentro: el cálculo exacto de V

Lambert W, la recursión y cómo se arma la Tabla 1 del paper

Por dentro: ¿cómo se calcula V ?

¿Cómo se hace ese cálculo numérico, en la práctica?

Entre eventos, c_t queda fijo y μ_t crece:

$$\frac{\partial \text{LLR}_t}{\partial \mu_t} = 1 - \frac{c_t}{\mu_t} < 0 \quad \text{si } c_t > \mu_t$$

El rechazo solo puede pasar en el instante de un evento nuevo — alcanza con mirar ahí.

Dos herramientas para hacerlo exacto (no simulado):

- **Función W de Lambert**: resuelve $we^w = z$; da el instante donde n eventos cruzarían V .
- **Incrementos independientes de Poisson**: lo que pasa en un tramo nuevo no depende de lo anterior.

Paso 1 — el instante de cruce s_n

Para cada $n = 1, 2, 3, \dots$ buscamos s_n tal que, con exactamente n eventos ahí, el LLR da justo V :

$$(\mu_{s_n} - n) + n \ln \left(\frac{n}{\mu_{s_n}} \right) = V$$

Despejando, la ecuación queda de la forma $we^w = z$ (la definición de W), y resulta:

$$\mu_{s_n} = -n W(-e^{-1-V/n})$$

Con esto, $s_1 < s_2 < s_3 < \dots$ quedan calculados en forma cerrada — sin simular nada.

Lema: incrementos independientes de Poisson

Sea C_t un proceso de Poisson bajo H_0 (con μ_t conocida). Para $s < t$:

$$C_t - C_s \sim \text{Poisson}(\mu_t - \mu_s), \quad \text{independiente de } C_s$$

El conteo en un tramo nuevo no depende de lo que ya pasó — el proceso “no tiene memoria” entre tramos disjuntos.

Paso 2 — la recursión: ¿seguís vivo hasta s_n ?

$\pi_n(k) := P(C_{s_n} = k, \text{ no rechazado hasta la etapa } n), \text{ para } k = 0, \dots, n - 1.$

Caso base:

$$\pi_0(0) = 1$$

(en $s_0 = 0, C_0 = 0$ con certeza).

Paso recursivo — con $\Delta_n = \mu_{s_n} - \mu_{s_{n-1}}$, combinamos π_{n-1} con el incremento (Poisson(Δ_n), independiente) y truncamos a $k < n$:

$$\pi_n(k) = \sum_{j=0}^k \pi_{n-1}(j) P(\text{incremento} = k - j), \quad k = 0, \dots, n - 1$$

Sea $\Pi_n := \sum_k \pi_n(k)$ la probabilidad total de seguir vivo tras la etapa n ($\Pi_0 = 1$).

Paso 3 — sumar todo lo rechazado

Acá entra T : define cuándo parar, $n_{\max} := \min\{n : s_n \geq T\}$. Ahí el último tramo se achica para terminar justo en T (no en $s_{n_{\max}}$).

Como Π_n solo puede bajar, lo rechazado en la etapa n es $\Pi_{n-1} - \Pi_n$, y sumando hasta $n_{\max}$ la suma telescopa:

$$\alpha(V, T) = \sum_{n=1}^{n_{\max}} (\Pi_{n-1} - \Pi_n) = 1 - \Pi_{n_{\max}}$$

Ejemplo con $V = 2$, $T = 3$:

n	s_n	Π_n	$1 - \Pi_n$
1	0.053	0.9489	0.0511
2	0.317	0.9210	0.0790
3	0.720	0.9030	0.0970
$\vdots$	$\vdots$	$\vdots$	$\vdots$
8	3.000 (T)	0.8647	0.1353

Y con miradas discretas, ¿qué pasa?

Del cálculo exacto continuo a K miradas finitas, comparado por simulación

Discretización: el experimento

Hasta acá V es exacto para vigilancia **continua**. En la práctica se mira cada tanto: K miradas igualmente espaciadas en μ_t acumulado, $\mu_i = iT/K$.

Se deja el **mismo** V continuo fijo — no se recalibra por K , porque recalibrar escondería el efecto que se quiere mostrar. Simulando muchas trayectorias con ese V , se mide:

- α empírico: fracción que cruza V bajo H_0
- potencia empírica: fracción que cruza V bajo un RR verdadero, contra la potencia continua exacta

(con intervalos de Wilson al 95% para el error de simulación)

Discretización: es conservadora

Con $T = 50$, α nominal = 0.05, $RR = 1.5$ ($V = 3.82$, potencia continua = 80.3%):

K miradas	α empírico	potencia empírica
1	0.3%	69.6%
12	1.5%	76.3%
52	2.3%	77.9%
365	3.4%	79.5%
1000	3.9%	79.3%
continuo	5.0%	80.3%

Con pocas miradas, α real queda muy por debajo del nominal — y la potencia también cae. A medida que K crece, ambos suben **desde abajo** hacia el continuo, sin superarlo nunca: se puede explorar interactivamente en la pestaña “Discretización” de la app.

¿Y los datos reales de la demo?

Qué series se muestran en la app, de dónde salen, y qué tan fuerte es la evidencia

Datos públicos, no simulados — 120 meses (2016-2025) por serie, cada una contra su propio comparador contemporáneo:

Serie	Fuente	Observado	Esperado
ELIQUIS / Hemorragia	FAERS (openFDA)	16.908	5.074
HPV9 / Síncope	VAERS	2.249	2.467
MENB / Pirexia	VAERS	1.482	731

El esperado nunca es una tasa clínica: es siempre la fracción de reporte de un comparador del mismo mes (no-ELIQUIS para la primera; MNQ, la vacuna meningocócica de la misma visita adolescente, para las otras dos) aplicada al volumen de reportes de la serie de interés.

Por qué esto pesa menos que el ejemplo del paper

El paper usa el **Vaccine Safety Datalink**: ≈ 650.000 chicos, vacunación **registrada automáticamente** (denominador real de dosis) y diagnósticos de **historias clínicas** (evento real, no autorreportado).

FAERS y VAERS son **reporte espontáneo**: sin denominador real de dosis ni de expuestos — observado y esperado son ambos **conteos de reportes**, no incidencia clínica.

Eso exige supuestos extra:

- el comparador (no-ELIQUIS, o MNQ) reporta a una tasa parecida a la real
- el pareo por edad (MNQ) controla razonablemente los confusores
- comparar a nivel de reporte aproxima una comparación a nivel de paciente

Mismo test, MaxSPRT — pero acá ilustra la mecánica del método, no prueba causalidad.

- El SPRT clásico de Wald funciona, pero es demasiado sensible al RR elegido para la alternativa - un problema serio cuando no sabemos ese valor de antemano.
- MaxSPRT resuelve esto con una alternativa compuesta ($RR > 1$) y maximizando la verosimilitud en vez de fijar un valor.
- Existen versiones para datos Poisson y binomiales, cubriendo los diseños más usados en farmacovigilancia.
- Es un método que se sigue usando hoy en sistemas reales de vigilancia de vacunas y fármacos.

- Kulldorff, M., Davis, R. L., Kolczak, M., Lewis, E., Lieu, T. y Platt, R. (2011). *A Maximized Sequential Probability Ratio Test for Drug and Vaccine Safety Surveillance*. Sequential Analysis, 30(1), 58-78.
- Wald, A. (1945). *Sequential Tests of Statistical Hypotheses*. Annals of Mathematical Statistics.
- Lorden, G. (1973). *Open-Ended Tests for Koopman-Darmois Families*. Annals of Statistics.
- Lieu, T. A. et al. (2007). *Real-Time Vaccine Safety Surveillance for the Early Detection of Adverse Events*. Medical Care.