

MaxSPRT: vigilancia secuencial de seguridad de
vacunas

Un test de razón de verosimilitud secuencial con alternativa compuesta

Santiago Dandois y Santiago Olszevicki

Basado en Kulldorff, Davis, Kolczak, Lewis, Lieu y Platt (2011), *A Maximized Sequential Probability Ratio Test for Drug and Vaccine Safety Surveillance*, Sequential Analysis 30(1).

Un problema real de salud pública

El paper, sus autores, el CDC y por qué hace falta vigilancia después de la aprobación

Esto no nace de un ejercicio académico

El **CDC** —Centers for Disease Control and Prevention— es una de las principales agencias federales de salud pública de Estados Unidos. Vigila enfermedades y convierte datos clínicos en decisiones de alcance nacional.

- Presupuesto solicitado para 2025: **USD 9.683 millones**.
- Su Vaccine Safety Datalink reúne historias clínicas de **más de 10 millones de personas por año** y registros de **más de 180 millones de vacunaciones**.
- MaxSPRT nació para una necesidad concreta de ese sistema: **revisar semanalmente la seguridad de vacunas sin multiplicar las falsas alarmas**.

¿Por qué hace falta farmacovigilancia?

Antes de la aprobación, los ensayos clínicos permiten detectar efectos frecuentes. Pero su tamaño y su población seleccionada pueden ocultar eventos que aparecen:

- una vez cada decenas o cientos de miles de aplicaciones;
- muchos meses después;
- solamente en embarazadas, niños, adultos mayores u otros subgrupos.

Cuando el producto empieza a utilizarse masivamente, la pregunta pasa a ser:

¿Podemos detectar un riesgo raro lo antes posible, sin generar una alarma cada vez que miramos los datos?

El punto de partida: SPRT clásico

Cómo funciona y por qué fijar el riesgo relativo puede retrasar o perder una señal

¿Qué es el riesgo relativo?

$$RR = \frac{\text{casos observados}}{\text{casos esperados sin efecto de la vacuna}}$$

- $RR = 1$: no hay exceso, todo como se esperaba.
- $RR = 2$: el doble de casos que los esperados.
- $RR = 1.2$: un 20% más de casos que lo esperado.

SPRT clásico (Wald, 1945-47)

C_t : eventos adversos observados hasta t (en D días); μ_t los esperados bajo H_0 . El SPRT contrasta dos hipótesis **simples**:

$$H_0 : C_t \sim \text{Poisson}(\mu_t) \quad (\text{RR} = 1) \quad \text{vs.} \quad H_A : C_t \sim \text{Poisson}(\text{RR} \mu_t) \quad (\text{RR fija, a priori})$$

La tasa basal puede cambiar en el tiempo

En general, bajo H_0 puede plantearse un **proceso de Poisson no homogéneo**:

$$C_t \sim \text{Poisson}(\mu_t), \quad \mu_t = \int_0^t \lambda_0(s) \, ds$$

La intensidad basal $\lambda_0(s)$ puede variar por estacionalidad, volumen de vacunación, campañas, días hábiles, etc. No se supone una tasa constante: μ_t acumula la cantidad esperada de eventos hasta t .

Lo importante es que, para $s < t$, los incrementos en intervalos disjuntos sean independientes y satisfagan

$$C_t - C_s \sim \text{Poisson}(\mu_t - \mu_s) \quad \text{bajo } H_0.$$

Aquí C_t es el conteo aleatorio y c_t es el valor acumulado efectivamente observado.

SPRT clásico: construcción de la verosimilitud

El estadístico es la razón de verosimilitudes $LR_t = P(\text{datos}|H_A)/P(\text{datos}|H_0)$. Para armarla, partimos $[0, t]$ en intervalos $i = 1, \dots, t$ con n_i eventos y μ_i esperados, independientes:

$$n_i \sim \text{Poisson}(\mu_i) \text{ bajo } H_0, \quad n_i \sim \text{Poisson}(\text{RR } \mu_i) \text{ bajo } H_A$$

La verosimilitud conjunta es la productoria de las densidades Poisson:

$$L_t(\text{RR}) = \prod_{i=1}^t \frac{e^{-\text{RR } \mu_i} (\text{RR } \mu_i)^{n_i}}{n_i!}$$

SPRT clásico: de la verosimilitud al estadístico

Reagrupando la productoria (exponenciales se suman, potencias de $\mathbf{RR}$ se acumulan):

$$L_t(\mathbf{RR}) = e^{-\mathbf{RR} \mu_t \mathbf{RR}^{c_t}} \prod_{i=1}^t \frac{\mu_i^{n_i}}{n_i!}$$


con $\mu_t = \sum_i \mu_i$ y $c_t = \sum_i n_i$. El último factor no depende de $\mathbf{RR}$ y se cancela en el cociente:

$$\text{LR}_t = \frac{L_t(\mathbf{RR})}{L_t(1)} = e^{(1-\mathbf{RR})\mu_t \mathbf{RR}^{c_t}} \Rightarrow \text{LLR}_t = (1 - \mathbf{RR})\mu_t + c_t \ln(\mathbf{RR})$$

Regla: señal si $\text{LLR}_t \geq \ln[(1 - \beta)/\alpha] = 2.77$; se acepta H_0 si $\text{LLR}_t \leq \ln[\beta/(1 - \alpha)] = -1.56$ ($\alpha = 0.05, \beta = 0.20$).

Hay que fijar el $\mathbf{RR}$ de antemano — ese “detalle” es el problema.

El problema del SPRT clásico (I): fiebre




Pediarix, ≈ 650.000 chicos (Vaccine Safety Datalink). El RR verdadero termina en ≈ 1.16 .

- con $H_A : RR = 1.2$ (cerca del real) $\rightarrow$ **señal a las 13 sem.**
- con $H_A : RR = 2.0$ (lejos del real) $\rightarrow$ cruza el límite inferior y **acepta H_0 a las 7 sem:** no detecta nada.

La alternativa mal elegida (2.0) hace **perder** un riesgo real.

El problema del SPRT clásico (II): síntomas neurológicos



Mismos datos, otro evento. Acá el RR verdadero termina en ≈ 2.75 .

- con $H_A : RR = 2.0$ (cerca del real) $\rightarrow$ **señal a las 32 sem.**
- con $H_A : RR = 1.2$ (lejos del real) $\rightarrow$ **señal recién a las 65 sem.**

Ambas detectan, pero elegir mal el RR **retrasa la señal** casi 8 meses: el tiempo hasta la alarma depende del RR fijado a priori, que casi nunca conocemos.

MaxSPRT: vigilar sin adivinar el riesgo

La alternativa compuesta y el modelo Poisson

La idea de MaxSPRT

El SPRT clásico obliga a fijar el **RR** de la alternativa antes de ver los datos.

MaxSPRT usa una alternativa **compuesta**:

$$H_0 : \text{RR} = 1 \quad \text{vs.} \quad H_A : \text{RR} > 1$$

Clave: se **apoya en el mismo LLR_t ya deducido**. En vez de un **RR** fijo, se usa el **RR** que maximiza la verosimilitud — estimado de los datos, no elegido a priori:

$$\text{LLR}_t = \max_{\text{RR} \geq 1} [(1 - \text{RR})\mu_t + c_t \ln(\text{RR})]$$

(razón de verosimilitud generalizada, Lorden 1973). No hay que adivinar el **RR** “interesante”: el test busca el que mejor explica lo observado. Se paga algo de potencia, pero es mucho más robusto.

Maximizando sobre RR

Derivando LLR_t respecto de RR e igualando a cero, el máximo se da en el RR que iguala lo observado con lo esperado:

$$\frac{\partial \text{LLR}_t}{\partial \text{RR}} = -\mu_t + \frac{c_t}{\text{RR}} = 0 \quad \Rightarrow \quad \widehat{\text{RR}}_t = \frac{c_t}{\mu_t}$$

Ese es el estimador sin restricción. Como la alternativa solo admite $\text{RR} \geq 1$, el estimador restringido es

$$\widehat{\text{RR}}_{t,\text{restr}} = \max\left(1, \frac{c_t}{\mu_t}\right)$$

Por eso solo toma el valor $\frac{c_t}{\mu_t} > 1$ cuando $c_t > \mu_t$; si $c_t \leq \mu_t$, el máximo queda en el borde $\text{RR} = 1$ y el LLR vale cero.

Sustituyendo $\widehat{RR}_t = c_t / \mu_t$:

$$LLR_t = (\mu_t - c_t) + c_t \ln \left(\frac{c_t}{\mu_t} \right)$$

y $LLR_t = 0$ si $c_t \leq \mu_t$ (no hay evidencia de exceso).

Regla, monitoreada continuamente:

- se sigue vigilando mientras LLR_t no llegue a un valor crítico V
- se rechaza H_0 apenas $LLR_t \geq V$ (señal)
- ya no hay límite inferior para “aceptar” H_A - no interesa frenar si la vacuna resulta protectora
- sí hay un límite superior T en la duración de la vigilancia (cantidad esperada de eventos bajo H_0), para no vigilar para siempre

Cuando no conocemos los casos esperados

La variante binomial: comparar eventos entre expuestos y controles

Y si no tenemos μ_t confiable...

A veces no hay tasa basal esperada confiable. Se compara directamente tiempo expuesto vs. no expuesto (diseño pareado, en vez de Poisson):

- autocontrolado: mismo individuo, ventana expuesta vs. no expuesta
- con controles: expuestos vs. no expuestos, pareados por edad/sexo

Cada evento cae del lado expuesto o no. Sea z la razón de oportunidades no expuestas sobre expuestas (tiempo, personas o controles).

$$H_0 : P(\text{expuesto}) = \frac{1}{z + 1} \quad H_A : P(\text{expuesto}) = \frac{\text{RR}}{\text{RR} + z}$$

Solo en un pareo 1:1, $z = 1 \rightarrow P(\text{expuesto}) = \frac{1}{2}$; con dos controles, $z = 2$ y vale $\frac{1}{3}$.

El límite de vigilancia ya no se mide en eventos esperados (T) sino en eventos observados en total (N).

MaxSPRT binomial: la verosimilitud

Sea c_n la cantidad de esos n eventos que cae del lado expuesto. Condicional en n , C_n es binomial (prob. p de caer expuesto):

$$P(C_n = c_n) = \binom{n}{c_n} p^{c_n} (1 - p)^{n - c_n}$$

Esa p depende del RR: $p(\text{RR}) = \text{RR}/(\text{RR} + z)$ y $1 - p = z/(\text{RR} + z)$. Reemplazando:

$$P(C_n = c_n \mid \text{RR}) = \binom{n}{c_n} \left(\frac{\text{RR}}{\text{RR} + z} \right)^{c_n} \left(\frac{z}{\text{RR} + z} \right)^{n - c_n}$$

El cociente contra H_0 ($p = 1/(z + 1)$) cancela $\binom{n}{c_n}$ y se maximiza sobre $\text{RR} > 1$:

$$\text{LR}_{n(\text{RR})} = \frac{\left(\frac{\text{RR}}{\text{RR} + z} \right)^{c_n} \left(\frac{z}{\text{RR} + z} \right)^{n - c_n}}{\left(\frac{1}{z + 1} \right)^{c_n} \left(\frac{z}{z + 1} \right)^{n - c_n}}$$

Maximizar la binomial sobre p da el estimador de proporción $\hat{p} = c_n/n$, que corresponde a $\widehat{RR}_n = zc_n/(n - c_n)$. Reemplazando, el numerador queda

$$(c_n/n)^{c_n} ((n - c_n)/n)^{n-c_n}$$

y el estadístico es:

$$LLR_n = c_n \ln\left(\frac{c_n}{n}\right) + (n - c_n) \ln\left(\frac{n - c_n}{n}\right) - c_n \ln\left(\frac{1}{z + 1}\right) - (n - c_n) \ln\left(\frac{z}{z + 1}\right)$$

(válido si $zc_n/(n - c_n) > 1$; si no, $LLR_n = 0$: no hay exceso del lado expuesto).

Misma lógica que el caso Poisson —alternativa compuesta $RR > 1$, maximización de la verosimilitud, tablas de valores críticos— pero partiendo de la binomial en vez de la Poisson. La frontera binomial se calibra para (α, N, z) .

¿Cómo se decide cuándo alertar?

Horizonte, umbral crítico, potencia y construcción exacta de las tablas del paper


El umbral crítico controla las falsas alarmas

V controla el error de tipo I: el valor más chico tal que, bajo H_0 , la probabilidad de cruzarlo alguna vez antes de T sea α .

$$P_{H_0}(\exists t \leq T : \text{LLR}_t \geq V) = \alpha$$

No hay fórmula cerrada: α se calcula con una recursión numérica bajo H_0 , y se ajusta V hasta ese valor. Tabulado por (α, T) una vez, no hace falta recalcularlo.

El LLR baja entre eventos y salta cuando llega uno



μ_t , la cantidad acumulada de eventos esperados, es una función estrictamente creciente. Por eso hay una correspondencia biyectiva entre el tiempo transcurrido y los eventos esperados. La vigilancia termina al cruzar V o, si no hay señal, al llegar a T .

El horizonte determina el umbral

Para $\alpha = 0.05$, algunos ejemplos de valores críticos son:

Horizonte T	Umbral crítico V
2	≈ 3.05
10	≈ 3.47
800	≈ 4.29

A mayor T , mayor V : se permiten más chances de cruzarlo por azar, así que hace falta una señal más fuerte para mantener el mismo α .

Un horizonte mayor permite detectar incrementos de riesgo más moderados, pero exige acumular evidencia durante más tiempo.

Por dentro: ¿cómo se calcula V ?

¿Cómo se hace ese cálculo numérico, en la práctica?

Entre eventos, c_t queda fijo y μ_t crece:

$$\frac{\partial \text{LLR}_t}{\partial \mu_t} = 1 - \frac{c_t}{\mu_t} < 0 \quad \text{si } c_t > \mu_t$$

El rechazo solo puede pasar en el instante de un evento nuevo — alcanza con mirar ahí.

Dos herramientas para hacerlo exacto (no simulado):

- **Función W de Lambert**: resuelve $we^w = z$; da el instante donde n eventos cruzarían V .
- **Incrementos independientes de Poisson**: lo que pasa en un tramo nuevo no depende de lo anterior.

Paso 1a — normalizar la ecuación de cruce

Para cada $n = 1, 2, 3, \dots$ buscamos s_n tal que, con exactamente n eventos ahí, el LLR da justo V :

$$(\mu_{s_n} - n) + n \ln \left(\frac{n}{\mu_{s_n}} \right) = V$$

Definimos $x = \mu_{s_n}/n$. Como el rechazo exige un exceso, buscamos $0 < x < 1$.

Dividiendo por n :

$$x - 1 + \ln \left(\frac{1}{x} \right) = \frac{V}{n}$$

$$x - \ln x = 1 + \frac{V}{n}$$

Paso 1b — llevarla a la forma de Lambert W

Primero aislamos el logaritmo y exponenciamos:

$$\ln x = x - 1 - \frac{V}{n}$$

$$x = e^{x-1-\frac{V}{n}}$$

Luego multiplicamos por e^{-x} y por -1 :

$$xe^{-x} = e^{-1-\frac{V}{n}}$$

$$(-x)e^{-x} = -e^{-1-\frac{V}{n}}$$

Ahora el lado izquierdo tiene exactamente la forma we^w , con $w = -x$.

Paso 1c — invertir y elegir la rama correcta

La función de Lambert satisface $W(z)e^{W(z)} = z$. Por lo tanto:

$$-x = W_0\left(-e^{-1-\frac{V}{n}}\right)$$

y, volviendo a $\mu_{s_n} = nx$:

$$\mu_{s_n} = -nW_0\left(-e^{-1-V/n}\right)$$

Se usa la rama principal W_0 : produce $0 < x < 1$. La rama W_{-1} da $x \geq 1$, fuera de la región de exceso del test unilateral.

Así obtenemos cada punto de cruce en la escala de media esperada, μ_{s_n} , sin simular trayectorias continuas.

Lema: incrementos independientes de Poisson

Bajo H_0 , sea C_t un proceso de Poisson con media acumulada conocida μ_t . Para $s < t$:

$$C_t - C_s \sim \text{Poisson}(\mu_t - \mu_s), \quad \text{independiente de } C_s$$

El conteo en un tramo nuevo no depende de lo que ya pasó — el proceso “no tiene memoria” entre tramos disjuntos.

Paso 2 — la recursión: ¿seguís vivo hasta s_n ?

$\pi_n(k) := P(C_{s_n} = k, \text{ no rechazado hasta la etapa } n), \text{ para } n \geq 1 \text{ y } k = 0, \dots, n-1.$

Caso inicial: en la primera etapa, seguir sin rechazo exige no haber observado eventos:

$$\pi_1(0) = P(C_{s_1} = 0) = e^{-\mu_{s_1}}$$

Paso recursivo — para $n \geq 2$, con $\Delta_n = \mu_{s_n} - \mu_{s_{n-1}}$, combinamos π_{n-1} con el incremento (Poisson(Δ_n), independiente) y truncamos a $k < n$:

$$\begin{aligned}\pi_n(k) &= \sum_{j=0}^{\min(k, n-2)} \pi_{n-1}(j) P(\text{incremento} = k-j) \\ &= \sum_{j=0}^{\min(k, n-2)} \pi_{n-1}(j) e^{-\Delta_n} \frac{\Delta_n^{k-j}}{(k-j)!}, \quad k = 0, \dots, n-1\end{aligned}$$

Paso 3 — sumar todo lo rechazado

Sea $\Pi_n := \sum_{k=0}^{n-1} \pi_{n(k)}$ la probabilidad total de no rechazar tras la etapa n . Definimos por separado $\Pi_0 := 1$: antes de la primera etapa, la vigilancia sigue activa con certeza.

Acá entra T : define cuándo parar,

$$n_{\max} := \min \left\{ n : \mu_{s_n} \geq T \right\}.$$

En la última etapa no avanzamos hasta $\mu_{s_{n_{\max}}}$: usamos el incremento $T - \mu_{s_{n_{\max}-1}}$ para terminar exactamente en el horizonte.

Π_n es la probabilidad de continuar sin rechazo después de la etapa n . Por lo tanto, $\Pi_{n-1} - \Pi_n$ es la probabilidad de rechazar precisamente durante la etapa n . Al sumar sobre todas las etapas obtenemos una suma telescópica:

$$\alpha(V, T) = \sum_{n=1}^{n_{\max}} (\Pi_{n-1} - \Pi_n) = 1 - \Pi_{n_{\max}}$$

Ejemplo de la recursión

Ejemplo con $V = 2$, $T = 3$. Definimos $u_n := \min(\mu_{s_n}, T)$:

$$\mu_{s_7} = -7W_0(-e^{-1-\frac{2}{7}}) \approx 2.949$$

$$\mu_{s_8} = -8W_0(-e^{-1-\frac{2}{8}}) \approx 3.590$$

$$\mu_{s_7} < T < \mu_{s_8} \rightarrow n_{\max} = 8$$

n	u_n	Π_n	$1 - \Pi_n$
1	0.053	0.9489	0.0511
2	0.317	0.9210	0.0790
3	0.720	0.9030	0.0970
$\vdots$	$\vdots$	$\vdots$	$\vdots$
8	3.000 (T)	0.8647	0.1353

$$\alpha(V = 2, T = 3) = 1 - \Pi_8 = 0.1353$$

Paso 4 — invertir $\alpha(V, T)$ para obtener V

La recursión anterior responde: dado un candidato V , ¿cuánto vale el error real $\alpha(V, T)$ bajo H_0 ?

Para construir la Tabla 1 fijamos T y el α deseado, y resolvemos:

$$f(V) := \alpha(V, T) - \alpha_0 = 0$$

Subir V hace más difícil rechazar, así que $\alpha(V, T)$ es decreciente. Por lo tanto, es fácil buscar la raíz numéricamente.

Cada evaluación vuelve a ejecutar la cadena completa:

Lambert $W \rightarrow$ grilla $\mu_{s_n} \rightarrow$ recursión Poisson $\rightarrow$ masa absorbida $\alpha(V, T)$.

Valores críticos para distintos horizontes

Horizonte T	$\alpha = 0.05$	$\alpha = 0.01$	$\alpha = 0.001$
0.1	2.04407	4.11929	6.57967
0.5	2.63793	4.48374	7.03447
1	2.85394	4.67043	7.17261
2	3.04698	4.86222	7.34145
5	3.29718	5.09191	7.56931
10	3.46795	5.26051	7.72486
50	3.81990	5.60597	8.06707
100	3.95232	5.73897	8.19940
500	4.22263	6.01109	8.47318
1000	4.32492	6.11423	8.57725

De vigilancia continua a revisiones periódicas

Qué cambia al mirar cada semana o cada mes, en lugar de hacerlo ante cada evento

Discretización: el experimento

Hasta acá V es exacto para vigilancia **continua**. En la práctica se mira cada tanto: K miradas igualmente espaciadas en μ_t acumulado, $\mu_i = iT/K$.

Se deja el **mismo** V continuo fijo — no se recalibra por K , porque recalibrar escondería el efecto que se quiere mostrar. Simulando muchas trayectorias con ese V , se mide:

- α empírico: fracción que cruza V bajo H_0
- potencia empírica: fracción que cruza V bajo un RR verdadero, contra la potencia continua exacta

Dos fuentes, tres series de reportes

Usamos datos públicos mensuales de 2016 a 2025:

Fuente	Producto	Evento buscado
FAERS / openFDA	ELIQUIS	Haemorrhage
VAERS	HPV9 (GARDASIL 9)	Syncope
VAERS	MENB	Pyrexia

Cada fila representa reportes recibidos, no todas las personas expuestas ni todas las dosis administradas.

¿Contra qué comparamos cada serie?

ELIQUIS: usamos como referencia los reportes no-ELIQUIS del mismo mes.

$$E_t = \text{reportes ELIQUIS}_t \times \frac{\text{Haemorrhage en no-ELIQUIS}_t}{\text{reportes no-ELIQUIS}_t}$$

HPV9 y MENB: usamos MNQ —vacuna meningocócica ACWY de la misma visita adolescente— como comparador contemporáneo.

$$E_t = \text{reportes de la vacuna}_t \times \frac{\text{evento en MNQ}_t}{\text{reportes MNQ}_t}$$

En la pestaña **Binomial MENB vs MNQ** no construimos esperados Poisson: comparamos directamente las proporciones mensuales de reportes con Pyrexia, condicionando por los totales del mes.

La demo permite mostrar con datos reales:

- cómo evolucionan MaxSPRT y los SPRT clásicos;
- cuándo aparece una señal secuencial.

¡Veámoslo en acción!

Shiny R app

Cerrando

Conclusiones principales

- El SPRT clásico de Wald funciona, pero es demasiado sensible al RR elegido para la alternativa - un problema serio cuando no sabemos ese valor de antemano.
- MaxSPRT resuelve esto con una alternativa compuesta ($RR > 1$) y maximizando la verosimilitud en vez de fijar un valor.
- Existen versiones para datos Poisson y binomiales, cubriendo los diseños más usados en farmacovigilancia.
- Es un método que se sigue usando hoy en sistemas reales de vigilancia de vacunas y fármacos.

- Kulldorff, M., Davis, R. L., Kolczak, M., Lewis, E., Lieu, T. y Platt, R. (2011). *A Maximized Sequential Probability Ratio Test for Drug and Vaccine Safety Surveillance*. *Sequential Analysis*, 30(1), 58-78.
- Centers for Disease Control and Prevention (2024). *Chapter 4: Vaccine Safety*. *Epidemiology and Prevention of Vaccine-Preventable Diseases (Pink Book)*.
- Centers for Disease Control and Prevention (2024). *FY 2025 CDC Budget Overview*. Office of Financial Resources.
- Wald, A. (1945). *Sequential Tests of Statistical Hypotheses*. *Annals of Mathematical Statistics*.
- Lorden, G. (1973). *Open-Ended Tests for Koopman-Darmois Families*. *Annals of Statistics*.
- Lieu, T. A. et al. (2007). *Real-Time Vaccine Safety Surveillance for the Early Detection of Adverse Events*. *Medical Care*.